

**MBA
USP
ESALQ**

**Predição da Temperatura Interna
de Ratos Macho Sob Estresse
Térmico não compensado Usando
Machine Learning Supervisionado**

Letícia Aparecida Gontijo
Ana Julia Righetto

Fisiologia e Termorregulação

O exercício gera um desequilíbrio transitório entre produção de calor metabólico e dissipação ambiental.

- A elevação da T_{CORE} influencia a atividade enzimática e o fluxo sanguíneo.
- Hipertermia excessiva reduz o desempenho e aumenta riscos à homeostase.
- Ratos utilizam a vasodilação cutânea (cauda) como principal mecanismo de perda.

Modelos atuais

Abordagem Estatística Linear

Modelos convencionais falham em capturar relações não lineares complexas entre variáveis fisiológicas e ambientais durante o exercício vigoroso.

Variáveis Omitidas

Muitas análises ignoram a temperatura da pele (T_{SKIN}), reduzindo significativamente o poder preditivo dos modelos de hipertermia.

Objetivo do Estudo

Desenvolver e avaliar modelos de Machine Learning Supervisionado capazes de prever a temperatura interna (TCORE) de ratos a partir de dados fisiológicos e ambientais.

Método

Etapa	Descrição
Fonte	Dados de Andrade et al. (2023): 353 registros de ratos machos em esteira.
Limpeza	Verificação de consistência, tratamento de valores ausentes e remoção de erros.
Divisão	70% para treinamento dos modelos e 30% para teste/avaliação.
Normalização	Padronização de unidades para reduzir influência de escalas distintas.

Método

Algoritmos Aplicados:

Lasso:	Regressão linear regularizada.
SVR:	Support Vector Regressor para alta dimensão.
Random Forest:	Conjunto de árvores de decisão.
XGBoost:	Gradient Boosting sequencial otimizado.

Resultados e discussão

Base	Colunas	Principais Variáveis (Features)
DS1	7	Km, WBGT, Tskin, HR, Sexo, Idade, VO2max.
DS2	8	Variáveis do DS1 + Velocidade (Speed).
DS3	12	Variáveis do DS2 + Umidade (RH), VO2, DT, WT, AH.

Método

O **XGBoost** otimiza árvores de decisão sequencialmente, minimizando resíduos de forma iterativa.

$$R^2 = 0,821$$

Esta arquitetura permite mapear as interações não lineares complexas da termorregulação.

Método

Dimensionalidade

O aumento de 8 para 12 variáveis (DS3) não melhorou o erro, indicando redundância e colinearidade entre os preditores.

Preditores Chave

T_{SKIN} , Frequência Cardíaca e WBGT sumarizam as restrições termorregulatórias e cardiovasculares críticas.

Conclusão

- O XGBoost apresentou o melhor desempenho preditivo independente da base de dados.
- Modelos baseados em ensemble superam abordagens lineares para representar fenômenos biológicos dinâmicos.
- O desempenho está mais ligado à abordagem algorítmica do que ao simples aumento do número de variáveis.